

PROPOSAL PRODUK

JalurAI

Sistem Prediksi Risiko Distribusi Berbasis Kecerdasan Buatan untuk Mendukung Efisiensi Biaya Logistik Nasional

Kategori: Smart Logistics
AI Innovation Challenge (AIC) — COMPFEST 18

Diajukan oleh: [Nama Tim]
Agustus 2026

Ringkasan Eksekutif

JalurAI adalah sistem yang memprediksi risiko keterlambatan dan kelebihan biaya pada setiap pesanan distribusi barang, sebelum barang tersebut dikirim. Sistem ini menggabungkan model klasifikasi dan regresi berbasis XGBoost, rule engine berbasis aturan domain, lapisan penjelasan menggunakan SHAP, dan Resolver Agent berbasis model bahasa besar dengan kemampuan tool calling, untuk menghasilkan skor risiko konsensus beserta rekomendasi tindakan yang langsung dapat dipahami staf operasional distribusi.

Produk ini menyasar masalah disparitas biaya dan waktu kirim antara wilayah Jawa dan luar Jawa yang masih berkisar 20 hingga 40 persen (Suara.com, 2026), sekaligus berkontribusi pada agenda nasional penurunan rasio biaya logistik terhadap PDB dari 14,29 persen menuju target 8 persen pada 2045 (Kementerian Perhubungan RI, 2024).

BAB I — Latar Belakang

Rasio biaya logistik nasional terhadap Produk Domestik Bruto tercatat sebesar 14,29 persen pada periode 2022 sampai 2023, berdasarkan perhitungan bersama Badan Pusat Statistik, Bappenas, dan Kementerian Koordinator Bidang Perekonomian (Kabarbursa, 2026). Angka ini turun dari 23,8 persen pada 2018, tetapi masih jauh dari negara maju yang berada di kisaran 8 sampai 10 persen dari PDB (Kabarbursa, 2026). Pemerintah menargetkan rasio ini turun menjadi 8 persen pada 2045 melalui reformasi sistem logistik nasional (Kementerian Perhubungan RI, 2024).

Sebagian dari beban tersebut berasal dari disparitas biaya dan waktu kirim antara wilayah Jawa dan luar Jawa, yang masih berkisar 20 sampai 40 persen (Suara.com, 2026). Lebih dari 60 persen distribusi barang nasional masih terkonsentrasi di Jawa, sementara sektor e-commerce yang menyumbang sekitar 77 persen ekonomi digital nasional melibatkan lebih dari 30 juta UMKM, merek, dan merchant yang bergantung pada layanan distribusi barang (Suara.com, 2026). Industri pos dan kurir memproses lebih dari 25 juta paket setiap hari (Suara.com, 2026), sehingga selisih kecil pada tingkat efisiensi rute berdampak besar secara agregat.

Peneliti Supply Chain Indonesia, Setijadi, mengingatkan bahwa tekanan biaya yang dirasakan pelaku UMKM di platform e-commerce tidak semata berasal dari ongkos kirim, melainkan akumulasi berbagai komponen biaya berjualan seperti komisi platform, biaya promosi, dan biaya retur (CNBC Indonesia, 2026). Ia tetap mengakui biaya logistik sebagai komponen penting, mengingat karakter Indonesia sebagai negara kepulauan membuat distribusi antarwilayah relatif mahal dan tidak seragam (CNBC Indonesia, 2026). Dengan kata lain, ongkos kirim bukan satu-satunya sumber masalah, tetapi tetap menjadi variabel

yang paling mungkin diintervensi lewat pendekatan berbasis data pada level operasional distributor.

Pada praktiknya, distributor kecil dan menengah umumnya baru menyadari sebuah pesanan berisiko tinggi, baik dari sisi keterlambatan maupun kelebihan biaya, setelah kejadian berlangsung. Keputusan alokasi rute dan estimasi biaya kirim masih banyak bergantung pada pengalaman staf secara manual, bukan pada analisis data historis performa rute. Akibatnya, pola kegagalan yang berulang pada rute atau kombinasi wilayah tertentu jarang terdeteksi lebih awal, dan biaya yang seharusnya bisa dicegah baru diketahui setelah pesanan selesai diproses.

Upaya efisiensi logistik nasional dapat dirumuskan secara sederhana sebagai $R_{\log} = C_{\log} / \text{PDB}$, yaitu rasio total biaya logistik terhadap PDB. Rasio ini bersifat makro dan dibentuk oleh jutaan transaksi distribusi setiap hari, sehingga intervensi yang realistis dilakukan lewat sebuah produk perangkat lunak berada pada level transaksi individual, bukan pada angka nasional secara langsung. JalurAI dirancang untuk beroperasi pada level tersebut, dengan menghitung indikator risiko untuk setiap pesanan sebagai unit analisis. Estimasi kontribusinya terhadap efisiensi nasional dibahas lebih lanjut pada bagian kesimpulan.

BAB II — Tujuan

Pengembangan JalurAI diarahkan pada empat tujuan berikut.

Pertama, membangun model klasifikasi dan regresi yang memprediksi risiko keterlambatan dan kelebihan biaya untuk setiap pesanan pengiriman, menggunakan data historis rute dan karakteristik pesanan sebagai input.

Kedua, menyediakan penjelasan atas setiap prediksi melalui analisis kontribusi fitur, sehingga staf operasional memahami penyebab risiko tersebut, bukan hanya menerima sebuah angka tanpa konteks.


Ketiga, menerjemahkan hasil prediksi dan penjelasan tersebut menjadi rekomendasi tindakan dalam bahasa Indonesia yang dapat langsung digunakan tanpa memerlukan interpretasi teknis tambahan dari staf yang tidak memiliki latar belakang data science.

Keempat, menyusun dasar arsitektur yang dapat dikembangkan lebih lanjut menjadi sistem rekomendasi realokasi stok antar hub distribusi, sebagai kelanjutan dari model prediksi risiko per pesanan yang dibangun pada tahap ini.

BAB III — Metodologi

3.1 Gambaran Umum Arsitektur

JalurAI dibangun sebagai satu alur pemrosesan yang berjalan secara sinkron, dari satu data pesanan sebagai input hingga satu keluaran akhir berupa skor risiko dan rekomendasi. Alur ini tersusun dari empat lapisan yang saling terhubung, sebagaimana digambarkan pada diagram berikut dan dirangkum pada Tabel 1.



Gambar 1. Alur pemrosesan JalurAI

Lapisan	Teknologi	Fungsi	Keluaran
Prediksi	XGBoost Classifier + Regressor	Mengklasifikasikan risiko pesanan dan memperkirakan besar keterlambatan atau kelebihan biaya	Skor risiko dan estimasi numerik
Heuristik	Rule engine berbasis aturan domain	Memberi flag risiko lewat aturan eksplisit yang diturunkan dari data disparitas wilayah, sebagai jaring pengaman saat data latih jarang mencakup suatu kasus	Flag risiko dan alasan aturan yang terpicu
Penjelasan	SHAP (TreeExplainer, mode tree_path_dependent)	Menguraikan kontribusi tiap fitur terhadap skor risiko dari XGBoost Classifier	Tiga fitur paling berpengaruh beserta arah pengaruhnya
Resolver Agent	LLM (API Gemini / Claude) dengan tool calling	Mengonsolidasikan hasil Prediksi, Heuristik, dan Penjelasan, memanggil tool tambahan hanya saat Prediksi dan Heuristik tidak sepakat	Skor risiko konsensus dan narasi rekomendasi

Tabel 1. Ringkasan empat lapisan arsitektur JalurAI

Keempat lapisan tersebut dijalankan dalam satu permintaan API, tanpa proses latar belakang maupun penjadwalan otomatis, sesuai dengan batasan ruang lingkup MVP tahap penyisihan yang dibahas pada bagian 3.5.

3.2 Alur Dataset

Data yang digunakan berupa data historis pesanan pengiriman, mencakup berat barang, dimensi kemasan, jarak tempuh, wilayah asal dan tujuan, jenis armada atau ekspedisi, nilai barang, serta riwayat performa rute berupa persentase keterlambatan pada rute tersebut dalam tiga bulan terakhir. Mengingat data operasional distributor bersifat tertutup dan tidak dapat diakses dalam waktu kompetisi, tim menyusun data sintetis yang polanya mengikuti temuan pada bagian latar belakang, khususnya kisaran disparitas biaya 20 sampai 40 persen antara rute Jawa dan luar Jawa (Suara.com, 2026).

Proses sintesis data dilakukan secara probabilistik, bukan lewat satu formula deterministik yang sama untuk seluruh rute. Setiap kombinasi rute dan wilayah diberi variasi biaya kirim mengikuti sebaran acak dengan dua modus, yang mewakili pesanan yang berjalan normal dan pesanan yang terkena gangguan seperti cuaca buruk atau lonjakan volume pengiriman, ditambah injeksi noise Gaussian pada tiap baris data. Pendekatan ini dipilih karena data yang terlalu bersih membuat model mudah mencapai akurasi sempurna pada data sintetis, padahal model tersebut hanya menghafal aturan pembuatannya sendiri, bukan mempelajari pola yang mendekati kondisi lapangan yang sesungguhnya berisik dan tidak konsisten.

Dari data mentah tersebut, disusun tiga fitur turunan. Rasio beban distribusi per pesanan, yaitu biaya kirim dibagi nilai barang pada pesanan tersebut, menjadi padanan mikro dari rasio biaya logistik nasional yang dibahas pada bagian latar belakang, dan menjadi target metrik utama yang dipantau model.

Indeks disparitas wilayah dihitung dari selisih rata-rata biaya kirim rute tersebut terhadap rata-rata biaya kirim rute internal Jawa sebagai baseline. Rasio jarak per kilogram ditambahkan untuk menangkap pesanan dengan kombinasi jarak jauh dan berat besar, yang secara historis berkorelasi dengan biaya tinggi.

Data numerik dinormalisasi dan data kategori seperti wilayah dan jenis armada di-encode sebelum dibagi menjadi data latih dan data uji dengan proporsi 80 banding 20.

3.3 Alur Pengembangan Model

Model inti terdiri dari dua tahap. Tahap pertama adalah XGBoost Classifier yang mengklasifikasikan setiap pesanan sebagai berisiko tinggi atau normal. Tahap kedua, khusus untuk pesanan yang diklasifikasikan berisiko tinggi, adalah XGBoost Regressor yang

memperkirakan besar kelebihan biaya atau lama keterlambatan dalam satuan hari. Kedua model dilatih dan disesuaikan penuh menggunakan data yang disusun tim sendiri, bukan model generik yang dipakai tanpa penyesuaian pada domain distribusi barang.

Berjalan paralel terhadap XGBoost, sebuah rule engine sederhana memeriksa pesanan terhadap aturan domain yang diturunkan dari data pada bagian latar belakang, misalnya pesanan menuju wilayah dengan disparitas biaya di atas ambang tertentu otomatis diberi flag risiko. Lapisan ini berfungsi sebagai jaring pengaman untuk kasus yang jarang muncul pada data latih, mengingat data sintesis yang dipakai tidak mungkin mencakup seluruh kombinasi rute dan kondisi yang ada di lapangan.

Penjelasan atas prediksi dihasilkan menggunakan pustaka SHAP dengan TreeExplainer pada mode `tree_path_dependent`, dan hanya diterapkan pada XGBoost Classifier. Fokus ini dipilih karena kebutuhan utamanya adalah menjelaskan mengapa sebuah pesanan dikategorikan berisiko tinggi, bukan menjelaskan setiap digit pada angka estimasi. Angka keterlambatan atau kelebihan biaya dari XGBoost Regressor ditampilkan sebagai data pendukung tanpa breakdown SHAP tersendiri, sehingga proses penjelasan tidak perlu dijalankan dua kali dan waktu komputasinya tetap dapat diprediksi. Mode `tree_path_dependent` sendiri dipilih karena tidak memerlukan dataset referensi tambahan, sebab informasi distribusi data latih sudah tersimpan dalam struktur pohon keputusan itu sendiri (Lundberg & Lee, dokumentasi SHAP). Dengan demikian waktu komputasi tetap konsisten meskipun volume data historis terus bertambah, berbeda dari mode `interventional` yang waktu prosesnya bertambah mengikuti ukuran dataset referensi yang digunakan.

Keluaran SHAP berupa tiga fitur dengan kontribusi terbesar terhadap skor risiko, disaring dan diubah ke format terstruktur di lapisan backend, misalnya `{"fitur": "rasio_jarak_per_kg", "arah": "meningkatkan_risiko", "besar_pengaruh": 0.25}`, sebelum dikirim ke Resolver Agent. Interpretasi arah pengaruh dilakukan di backend, bukan diserahkan ke model bahasa, untuk menghindari kesalahan pembacaan tanda kontribusi yang berpotensi menghasilkan narasi keliru.

Skor dari XGBoost Classifier, flag dari rule engine, dan breakdown SHAP tersebut dikonsolidasikan oleh Resolver Agent, sebuah lapisan berbasis model bahasa besar yang dipanggil dengan suhu rendah dan skema keluaran JSON yang ditentukan sejak prompt pertama (Strict JSON Mode), misalnya `{"skor_konsensus": string, "fitur_utama": string, "narasi": string, "rekomendasi": string}`. Apabila hasil XGBoost dan rule engine sepakat, Resolver Agent langsung menghasilkan narasi dan rekomendasi akhir. Apabila keduanya tidak sepakat, Resolver Agent memanggil satu tool tambahan berupa fungsi pemeriksa riwayat rute secara lebih rinci, sebelum menentukan skor konsensus akhir. Tool tambahan ini

hanya terpanggil pada kasus konflik, sehingga mayoritas pesanan tetap diproses dengan satu kali pemanggilan model bahasa dan waktu respons tetap dapat diprediksi.

Nilai pada field fitur_utama tetap dicocokkan secara lokal terhadap fitur teratas hasil SHAP tanpa memanggil ulang API. Apabila tidak cocok, backend langsung menimpa field tersebut dengan nilai dari SHAP sebelum hasil akhir dikirim ke antarmuka. Dengan desain ini tidak ada pemanggilan API tambahan di luar skenario konflik yang telah dijelaskan, maupun retry loop yang membuat waktu respons sulit diprediksi, sekaligus tetap menjamin fitur yang ditampilkan ke pengguna selalu sesuai dengan hasil SHAP walau model bahasa keliru menafsirkan data yang diberikan.

Desain Resolver Agent ini sejalan dengan klarifikasi resmi panitia AIC bahwa pemenuhan syarat kustomisasi model tidak harus lewat fine-tuning parameter, tetapi juga dapat dipenuhi lewat pendekatan agentic workflow dan tool calling, selama disesuaikan dengan inovasi fitur yang dibangun tim.

3.4 Alur Integrasi

Backend dibangun menggunakan FastAPI, menerima satu data pesanan melalui satu endpoint dan menjalankan seluruh pipeline secara sinkron sampai menghasilkan satu respons akhir. Data historis pesanan disimpan di MySQL dan digunakan untuk pelatihan ulang model secara berkala di luar alur inferensi utama. Antarmuka pengguna dibangun dengan Next.js dan Tailwind CSS berupa dashboard web yang menampilkan formulir input data pesanan beserta hasil skor risiko, fitur paling berpengaruh, dan rekomendasi tindakan. Pilihan ini disesuaikan dengan konteks penggunaannya, yaitu staf operasional gudang atau kantor distribusi yang bekerja dari komputer di satu lokasi tetap, sehingga dashboard web lebih pas dibanding aplikasi mobile yang ditujukan untuk pengguna yang berpindah tempat. Seluruh layanan dikemas dalam docker compose, sehingga dapat dijalankan secara lokal mengikuti panduan pada README tanpa konfigurasi tambahan.

3.5 Batasan Ruang Lingkup MVP Tahap Penyisihan

MVP yang disiapkan untuk tahap penyisihan mencakup satu alur inti secara utuh, yaitu satu data pesanan sebagai input, diproses melalui feature engineering, XGBoost, rule engine, SHAP, dan Resolver Agent, menghasilkan satu keluaran berisi skor risiko konsensus, tiga fitur paling berpengaruh, dan rekomendasi tindakan. Tidak ada proses latar belakang, penjadwalan otomatis, autentikasi pengguna, maupun penyesuaian parameter otomatis pada tahap ini, termasuk pada skenario tool calling di Resolver Agent yang tetap berjalan dalam satu siklus permintaan yang sama.

Modul visualisasi peta wilayah menggunakan GeoPandas atau Folium, serta modul rekomendasi realokasi stok antar hub distribusi, direncanakan sebagai pengembangan pada tahap final apabila tim lolos ke babak berikutnya. Pemisahan ini dilakukan agar MVP tahap penyisihan tetap dapat dijalankan dan diverifikasi secara lokal sesuai ketentuan kompetisi, sementara arsitektur yang lebih luas tetap tergambar jelas sebagai rencana pengembangan.

BAB IV — Kesimpulan

JalurAI dirancang untuk mendeteksi risiko keterlambatan dan kelebihan biaya pada setiap pesanan distribusi sebelum barang dikirim, menggunakan kombinasi model prediksi, rule engine, lapisan penjelasan, dan Resolver Agent yang menghasilkan rekomendasi tindakan yang mudah dipahami staf operasional.

Sebagai ilustrasi dampak, apabila sebuah distributor menerapkan JalurAI pada rute dengan disparitas biaya 20 sampai 40 persen dan berhasil mengalihkan sebagian pesanan berisiko tinggi ke rute atau jadwal yang lebih efisien, penurunan biaya pada level pesanan tersebut secara bertahap dapat berkontribusi pada penurunan rasio R_{log} secara nasional. Besar kontribusi pastinya tetap memerlukan pengujian pada data riil dan skala operasional yang lebih luas daripada yang dapat dicakup MVP ini.

Pengembangan lanjutan yang direncanakan tim mencakup pengujian model menggunakan data riil dari mitra distributor, penambahan modul visualisasi peta wilayah, serta modul rekomendasi realokasi stok antar hub sebagaimana disebutkan pada bagian 3.5. Tim juga akan mengevaluasi performa model secara berkala menggunakan data pesanan baru, mengingat pola disparitas biaya antarwilayah berpotensi berubah seiring perkembangan infrastruktur logistik nasional.

Daftar Pustaka

- Badan Pusat Statistik, Badan Perencanaan Pembangunan Nasional, & Kementerian Koordinator Bidang Perekonomian, sebagaimana dilaporkan dalam *Kabarbursa.com*. (2026). Biaya Logistik RI 14 Persen PDB, Pemerintah Percepat Reformasi. <https://www.kabarbursa.com/market-hari-ini/biaya-logistik-ri-14-persen-pdb-pemerintah-percepat-reformasi>
- CNBC Indonesia. (2026). Satu-Satu UMKM Tinggalkan E-commerce, Benar Cuma Efek Masalah Ongkir?. <https://www.cnbcindonesia.com/news/20260513155440-4-734804/satu-satu-umkm-tinggalkan-e-commerce-benar-cuma-efek-masalah-ongkir>

- Kementerian Perhubungan Republik Indonesia. (2024). Pemerintah Targetkan Turunkan Biaya Logistik menjadi 8 Persen dari PDB. <https://dephub.go.id/post/read/pemerintah-targetkan-turunkan-biaya-logistik-menjadi-8-persen-dari-pdb>
- Lundberg, S. M., & Lee, S. I. (t.t.). TreeExplainer. SHAP Documentation. <https://shap.readthedocs.io/en/latest/generated/shap.TreeExplainer.html>
- Suara.com. (2026). Pengusaha Jasa Kurir Janji Ikut Tekan Biaya Logistik Nasional yang Masih Tinggi. <https://amp.suara.com/bisnis/2026/06/24/105545/pengusaha-jasa-kurir-janji-ikut-tekan-biaya-logistik-nasional-yang-masih-tinggi>
- Tempo.co. (2023). BPS: Efisiensi Biaya Logistik Kurangi Ketimpangan Harga di Indonesia. <https://www.tempo.co/ekonomi/bps-efisiensi-biaya-logistik-kurangi-ketimpangan-harga-di-indonesia-143513>